博士生高性能计算与应用课程

天津大学超算中心 High Performance Computing Center

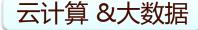
高性能计算热点问题: 云计算、大数据分析处理



Stat

信息技术的第三次浪潮







个人电脑

互联网

•第三次IT技术革命围绕物联网、移动互联网,云计算和大数据等技术,将会改变人们获取、处理、保存信息的方式

•以互联网为核心的第二次IT技术革命, 极大提高了信息交换和传播的效率

•以PC为核心的第一次IT技术革命,解决了信息本地处理的问题

想法

原型

测试

发布

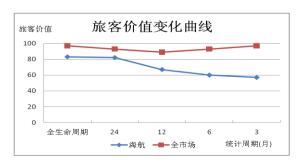
反复迭代 持续优化

身边的大数据: 航空信息服务

证件号码	姓名	常客类型	旅客价值(12个月)	
			H航	全市场
142431195906****	冯**	金卡	67	89

旅客价值变化趋势

统计周期	旅客价值		
近月月朔	H航	全市场	
全生命周期	83	97	
24	82	93	
12	67	89	
6	60	93	
3	57	97	

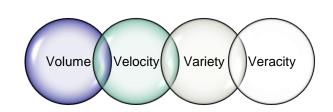


飞行次数统计

天津大学超算中心

统计日期(季	飞行次数		
度)	H航	全市场	
2007. 3	0	7	
2007. 4	1	11	
2008. 1	1	10	
2008. 2	1	5	
2008. 3	1	7	
2008. 4	0	1	
2009. 1	1	2	
2009. 2	1	6	
2009. 3	0	7	
2009. 4	0	12	
2010. 1	1	18	

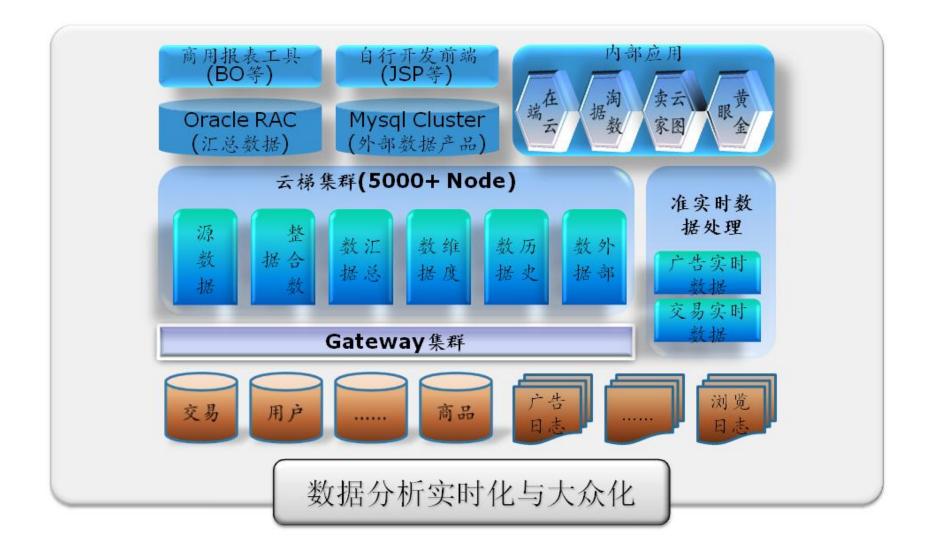
- 该旅客为北京、呼和浩特、成都航线上的高端商务旅客
- 该旅客通常选择前两排的高价座位,但不局限于头等舱
- 该旅客对同时为多家航空公司会员,但忠诚度不高
- 该旅客出临时行程非常多,一般提前1天或当天订票
- 该旅客通常在工作日出行,但对于具体时间不敏感



该旅客全市场价值很高,但是H航价值在不断降低,流失概率逐渐增大,建议加强服务。

Stat

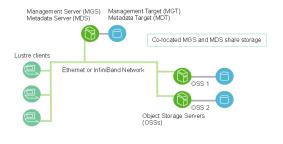
身边的大数据: 阿里云梯



Agenda

- The Eco-System for NGDC
 - DFS: Lustre/HDFS/Tachyon
 - No-SQL: MySQL Cluster/mongoDB/Cassandra
 - DCF: Virtualization/YARN/Spark
- Cloud Computing @TJUHPCC
 - vDesktop: Scale-up/Motion/Security
 - vCluster: Provisioning/Scale-out
 - Object Storage for Heterogeneous Computing
 - vHadoop by Serengeti

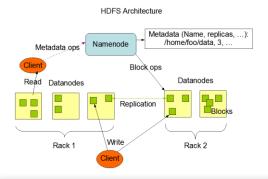
分布式文件系统



Lustre

- A storage architecture to stripe data across OSTs
- The number of objects per file is configurable
- http://wiki.lustre.org

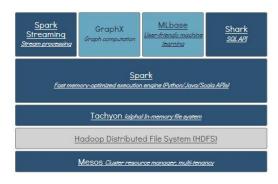




HDFS

- Primary distributed storage used by Hadoop
- File is stored as a sequence of blocks with Replication
- http://hadoop.apache.org





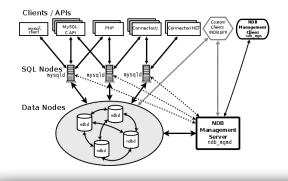
Tachyon

- Reliable File Sharing at Memory Speed Across Cluster Frameworks
- MR and Spark can run with it without modification
- http://tachyon-project.org



天津大学超算中心

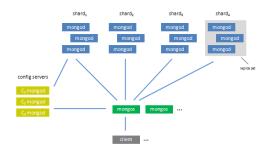
分布式数据库



MySQL Cluster

- A real-time, open source transactional database
- With in-memory clustered storage engine called NDB
- http://dev.mysql.com

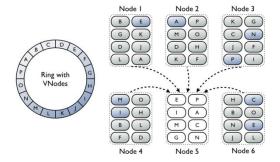




mongoDB

- An open-source document database written in C++
- JSON-style documents with dynamic schemas
- http://www.mongodb.org





Cassandra

- A decentralized multi-master database with no single points of failure
- Column indexes with log-structured updates
- http://cassandra.apache.org

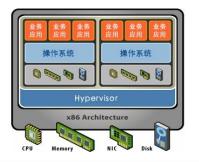


Cassandra DB

```
Hotel {
   key: AZC 043 { name: Cambria Suites Hayden, phone: 480-444-4444,
     address: 400 N. Hayden Rd., city: Scottsdale, state: AZ, zip: 85255}.
  key: AZS 011 { name: Clarion Scottsdale Peak, phone: 480-333-3333,
     address: 3000 N. Scottsdale Rd, city: Scottsdale, state: AZ, zip: 85255}
  key: CAS 021 { name: W Hotel, phone: 415-222-2222,
     address: 181 3rd Street, city: San Francisco, state: CA, zip: 94103}
  key: NYN 042 { name: Waldorf Hotel, phone: 212-555-555,
     address: 301 Park Ave, city: New York, state: NY, zip: 10019}
cassandra> get Hotelier.Hotel['NYN 042']
=> (column=zip, value=10019, timestamp=3894166157031651)
=> (column=state, value=NY, timestamp=3894166157031651)
=> (column=phone, value=212-555-5555, timestamp=3894166157031651)
=> (column=name, value=The Waldorf=Astoria, timestamp=3894166157031651)
=> (column=city, value=New York, timestamp=3894166157031651)
=> (column=address, value=301 Park Ave, timestamp=3894166157031651)
```

mongodb Collection

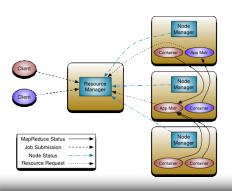
分布式计算框架



Server Virtualization

- XenServer: Industry leading open-source hypervisor for managing cloud, server and desktop virtual infrastructures
- http://www.citrix.com/products/xenserver

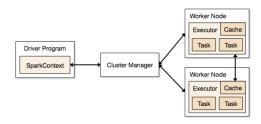




YARN / MapReduce 2.0 (MRv2)

- split up resource management and job scheduling of the JobTracker into separate daemons
- global RM with per-application Application Master
- http://hadoop.apache.org



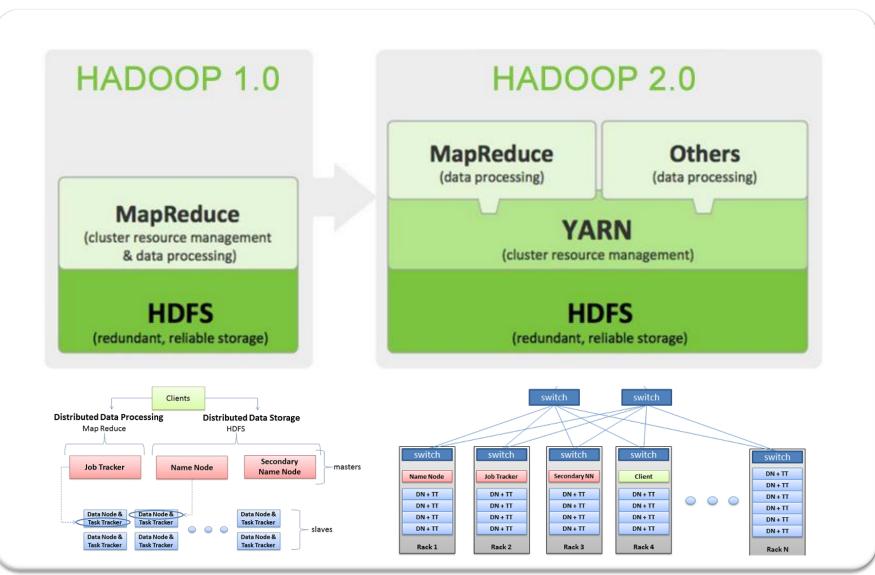


Spark

- An cluster engine supports in-memory computing
- Make data analytics fast to run and fast to write
- http://spark.incubator.apache.org



Hadoop Project



Agenda

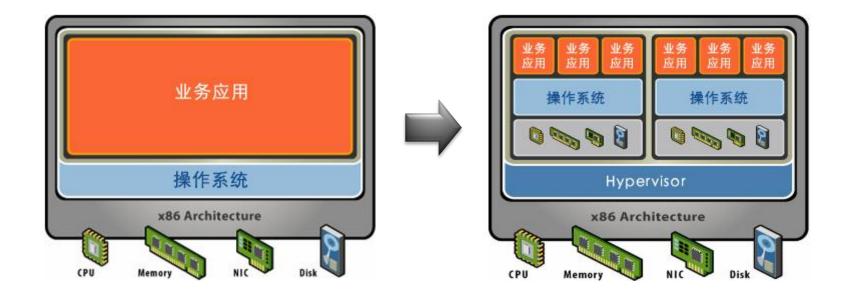
- The Eco-System for NGDC
 - DFS: Lustre/HDFS/Tachyon
 - No-SQL: MySQL Cluster/mongoDB/Cassandra
 - DCF: Virtualization/YARN/Spark
- Cloud Computing @TJUHPCC
 - vDesktop: Scale-up/Motion/Security
 - vCluster: Provisioning/Scale-out
 - Object Storage for Heterogeneous Computing
 - vHadoop by Serengeti

计算资源与计算服务



The Market

桌面虚拟化



桌面 虚拟化

- 支持弹性计算,快速部署与动态迁移等特性
- 最大64C/128GB内存,可部署主流Linux/Windows操作系统
- 已用于工程仿真Fluent,数值计算Matlab,渲染Maya等应用场景
- 使用客户端远程桌面通过校园网络进行连接

集群虚拟化



集群 虚拟化

- 使用PCMAE支持集群预先置备,快速部署与横向扩展
- 提供作业调度管理与集群状态监控功能,用户可具备集群root权限
- 测试阶段提供最大192C计算资源,8TB并行存储空间
- 使用SSHClient, Putty等客户端软件通过校园网络进行连接

大文件存储

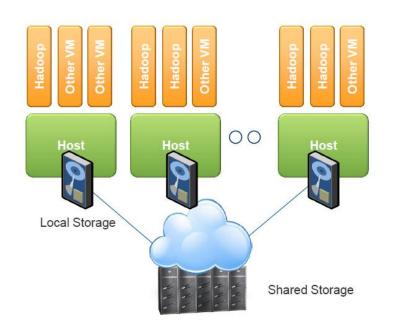


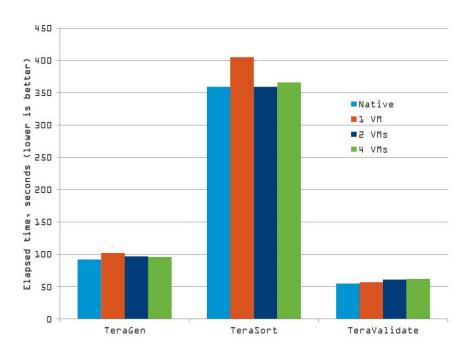
• 提供节点级元数据保护机制与磁盘配额管理

大文件 存储

- 可将单一目录同时挂载到计算集群和用户桌面
- 4个元数据节点,8个存储节点,合计40TB裸容量
- 基于标准x86 现用于满足托管集群与专用节点存储需求

Hadoop虚拟化





Hadoop 虚拟化

- Automate deployment and management of Apache Hadoop clusters on virtualized environments by Serengeti
- One command to scale out Apache Hadoop with Improved availability
- 使用SSHClient, Putty等客户端软件通过校园网络进行连接



更多信息



高效、便捷、可靠的科研高性能计算公共平台

首页

中心介绍

新闻动态

近期活动

用户服务

使用指南

应用案例

关于我们

触手可及的高性能计算

现在就开始使用集群提供的强大计算能力与海量存储 点击阅读高性能计算快速入门手册

通知通告

- 关于开通天津大学超算中心用户交流 群的通知
- 超算中心计算服务恢复通知
- 任务状态查询命令调整通知

工作动态 ...

- 天津大学参与的中欧超级计算战略合作项目正 式启动 阅读(148)
- 构建高性能计算公共平台 助力天大科研发展与 创新 阅读(211)
- · 天津大学超算中心ANSYS软件试用版部署完成 投入使用 阅读(295)
- 天津大学超算中心进入试运行阶段 阅读(186)



应用案例 ...

- 污泥流化床焚烧数值模拟
- 基于Illumina高通量测序平台的大规模RNAseg数据分析
- 序列与双硫键共同影响下的蛋白质热力学转变 问题研究





开户申请



机时预订



技术支持



流程查询

hpcc.tju.edu.cn QQ:245306022

衷心感谢!

